AVANCES EN LA PREDICCIÓN DE INDICADORES SOCIOECONÓMICOS MEDIANTE IMÁGENES SATELITALES

A. F. Ramírez-González, D. Vargas-Chanes*, E.D. Flores-Sol. Najera-Catalán, H.
PUED, Universidad Nacional Autónoma de México,
Av. Universidad 3000, C.U., 04510, Ciudad de México, México.
**Email: dvchanes@unam.mx,*
web page: http://www.pued.unam.mx/

M. Zea-Ortiz, P. Vera-Alfaro*
CICATA Unidad Querétaro, Instituto Politécnico Nacional,
Cerro Blanco 141, Querétaro, 76090, Querétaro, México.
**Email: pvera@ipn.mx*
web page: https://www.cicataqro.ipn.mx/

Resumen. Este estudio expande la investigación sobre la predicción de indicadores socioeconómicos mediante percepción remota, introduciendo un modelo basado en la arquitectura EfficientNetB7 para la estimación de pobreza multidimensional y de informalidad laboral a nivel municipal. Los modelos fueron adaptados para procesar imágenes satelitales multiespectrales de siete bandas (diurnas y nocturnas), entrenados a nivel de Área Geoestadística Básica para posteriormente agregar las predicciones a escala municipal y estatal. El desempeño de los modelos propuestos se comparó con modelos entrenados en EfficientNetB3, evaluando dos estrategias de procesamiento: uso directo de bandas y transformación logarítmica de la mediana. Los resultados demuestran que la arquitectura EfficientNetB7 ofrece mejoras en la capacidad predictiva, alcanzando un coeficiente de determinación R^2 de hasta 0.83 en pobreza y 0.82 en informalidad a nivel municipal, superando el 0.97 a nivel estatal.

Palabras clave: predicción de pobreza multidimensional, redes neuronales convolucionales, percepción remota – imágenes satelitales.

INTRODUCCIÓN

La creciente disponibilidad de imágenes satelitales, junto con la necesidad de generar información desagregada y frecuente sobre distintos

fenómenos sociales, ha dado lugar al desarrollo de modelos capaces de estimar indicadores sociales mediante algoritmos de visión computacional basados en Deep Learning que utilizan datos de percepción remota.

En años recientes, diversos estudios[1,2] han demostrado que las redes neuronales convolucionales (CNN por sus siglas en inglés) alcanzan altos niveles de precisión para la estimación de variables socioeconómicas. Sin embargo, el rendimiento de estos modelos depende en gran medida del tamaño de la arquitectura que se utilice y su alcance aún no está claro cuando se aplican a la predicción de indicadores sociales como la pobreza o la informalidad, el presente ejercicio muestra la eficiencia de su uso. Para probar el ajuste de los modelos, se realizan estimaciones de pobreza multidimensional en 2020 y 2015 e informalidad en 2020, México.

METODOLOGÍA

Los insumos necesarios para este ejercicio consisten en imágenes satelitales diurnas y nocturnas para el entrenamiento de los modelos. Las imágenes diurnas se obtuvieron de la plataforma de INEGI "Cubo de Imágenes Satelitales de México". La Geomediana, contiene 6 bandas espectrales (RGB y 3 infrarrojos) y con una resolución espacial de 30 metros por píxel. Por su parte, las imágenes nocturnas corresponden al producto "VNP64A1" del sensor VIIRS, disponible en la plataforma LAADS DAAC-NASA. Con resolución aproximada de 450 metros por píxel. Se desarrollaron dos escenarios, el primero es la estimación de pobreza multidimensional y el segundo la estimación de informalidad sectorial.

En el caso de la estimación de la pobreza multidimensional se utiliza la metodología previamente reportada[3] para la generación de las etiquetas de entrenamiento y la construcción de recortes de imágenes. En este caso, las imágenes se procesaron y el entrenamiento del modelo se realizó a nivel de Área Geoestadística Básica (AGEB). Para cada AGEB se generó un recorte de 40 x 40 pixeles centrado en el centroide del AGEB, lo que produjo un total de 81,428 imágenes correspondientes a la totalidad de AGEBs del país. Los valores municipales de pobreza multidimensional reportados para 2020[4] se asignaron a cada AGEB como etiquetas supervisadas. En este ejercicio, se presentan resultados utilizando los métodos de "sensor completo" (SC) y "Logaritmo de la mediana" (Log). El segundo ejercicio consistió en estimar la informalidad, para tal efecto se usó la misma metodología previamente entrenada pero ahora se sustituye la estimación de la informalidad a nivel municipal como etiqueta.[5]

Cambios en la arquitectura de red neuronal

Para trabajar con arreglos numéricos de 7 canales, fue necesario modificar la estructura original del modelo de CNN. EfficientNetB3 (EFNB3), se reemplazó la capa convolucional inicial para recibir una entrada de 7 bandas de 224x224 pixeles. Se realizó fine-tuning utilizando pesos preentrenados de "Imagenet". Para EfficientNetB7 (EFNB7), la transferencia de pesos entre ambos modelos se realizó mediante coincidencia por nombre de capa y se copiaron sus pesos. A las capas transferidas se les asignó una regularización L2. Para las capas incompatibles con el modelo preentrenado, se utilizó inicialización Xavier y como función de activación se usó la función sigmoide. Todos los modelos se entrenaron por un máximo de 35 épocas.

RESULTADOS

Se obtuvieron predicciones para cada una de las AGEB en el país, tanto para el ejercicio de pobreza como el de informalidad por separado. Sin embargo, no es posible evaluar de manera directa la precisión de las estimaciones a ese nivel, puesto que no existe información de pobreza e informalidad más granular que el municipal. Para ello, realizamos promedios ponderados por cada municipio del país utilizando la información poblacional de acuerdo con los datos del censo del 2020 de cada AGEB. Posteriormente replicamos el mismo proceso para obtener promedios estatales y nacionales. La siguiente tabla compara el ajuste de los nuevos modelos entrenados con su versión anterior.

	R^2	
Modelo	2015	2020
Nivel Municipal		
EFNB7 Log	0.56	0.83
EFNB7 SC	0.73	0.80
EFNB3 Log	0.69	0.71
EFNB3 SC	0.67	0.76
Nivel Estatal		
EFNB7 Log	0.58	0.98
EFNB7 SC	0.87	0.97
EFNB3 Log	0.89	0.95
EFNB3 SC	0.88	0.96

Tabla 1 : Comparativa de ajuste de coeficiente R^2 y estimación de la pobreza multidimensional entre los modelos EFNB3 y EFNB7 a nivel municipal y estatal para los años 2015 y 2020

Nota: Se usan datos de la Geomediana con datos del VIIRS 2015 y se utiliza el mismo procedimiento para el 2020

Los modelos entrenados con EFNB7 superan en varianza explicada a los modelos entrenados con EFNB3 en el año 2020. Los modelos de Log obtienen un ajuste superior a aquellos que usan el SC. Para las predicciones en 2015 se detectó que el modelo de Log no mantiene el nivel de ajuste de predicciones con respecto a los demás modelos, incluyendo su versión anterior de EFNB3.

En cuanto a informalidad, la tabla 2 describe el ajuste de los modelos entrenados en EFNB7 para el año 2020.

Municipal	
Modelo	R^2
EFNB7 Log	0.83
EFNB7 SC	0.66
Estatal	
EFNB7 Log	0.99
EFNB7 SC	0.97

Tabla 2: Ajuste de coeficiente R^2 en los modelos EFNB7 en la predicción de informalidad a nivel municipal y estatal para el año 2020

Nota: Se usan datos de la Geomediana con datos del VIIRS 2015 y se utiliza el mismo procedimiento realizado para el 2020

La estimación de la pobreza usando el modelo entrenado con EFNB7SC a nivel nacional es de 43.0 y 43.3 para los años 2015 y 2020 respectivamente. En tanto que la estimación de la informalidad para el 2020 es de 57.4.

CONCLUSIONES

Las arquitecturas CNN de gran escala, particularmente EfficientNetB7, mejoran la estimación de pobreza multidimensional e informalidad laboral a partir de imágenes satelitales. La estrategia Log obtiene el mejor ajuste global, aunque con menor estabilidad inter-temporal frente al sensor completo. En conjunto, los resultados refuerzan la evidencia empírica sobre la viabilidad de

enfoques basados en percepción remota y aprendizaje profundo para la estimación de indicadores socioeconómicos a escala municipal y estatal.

Estos ejercicios muestran la potencialidad de utilizar modelos de CNN y arquitecturas adecuadas para realizar estimaciones tanto de pobreza multidimensional como informalidad para años en los que no hay encuestas, siempre y cuando se tengan disponibles datos satelitales e información censal necesaria.

REFERENCIAS

[1] Yeh, C., Perez, A., Driscoll, A., Azzari, G., Tang, Z., Lobell, D., Ermon, S., Burke, M.: Using publicly available satellite imagery and deep learning to understand economic well-being in Africa. Nature Communications 11(1), 2583 (2020).

[2] Zea-Ortiz, M., Vera, P., Salas, J. et al. A data-driven approach to mapping multidimensional poverty at residential block level in Mexico. Environ Dev Sustain (2024).

[3] Ramírez-González, A. F., Zea-Ortiz, M., Vera-Alfaro, P., & Vargas-Chanes, D. (2025). *Exploring and evaluating multisource remote sensing for poverty mapping in Mexico: Integrating geomedian and VIIRS night-time light data* [Oral presentation]. **4th International Conference on Applied Science and Advanced Technology (ICASAT)**, *Technological and Scientific Innovation for a Sustainable Future*, Querétaro, Mexico, October 2, 2025.

[4] CONEVAL. (2022). Medición de la pobreza. https://www.coneval.org.mx/Medicion/MP/Paginas/Pobreza_2022.aspx

[5] Nájera,-Catalán, H. (2026). Estimación de informalidad mediante áreas pequeñas. México 2020. En Vargas-Chanes, D. (Coord). La economía vista desde el espacio: nuevas fronteras en la medición de la pobreza y el desarrollo económico local. PUED-UNAM. (publicación en proceso).